## homework2

3170102187 孙晨旭

## 1 Loading and cleaning

```
a.
ca_pa <- read_csv("~/github/Rcourse_1/data/calif_penn_2011.csv")</pre>
   b.rows and columns
dim(ca_pa)
## [1] 11275
                34
  c.
tail(colSums(apply(ca_pa,c(1,2),is.na)))
##
                Bedrooms_4
                                Bedrooms_5_or_more
                                                                     Owners
##
                                                 98
                                                                         100
                   Renters Median_household_income
##
                                                      Mean_household_income
##
                       100
                                                                         126
   apply 函数将 is.na() 作用于 ca_pa 的每一个元素, colSums() 统计每
一列中为 na 类型的元素个数。
   d.e.
ca_pa_1<-na.omit(ca_pa)</pre>
(delete_nrows = nrow(ca_pa)-nrow(ca_pa_1))
```

## [1] 670

f.

```
sum(apply(ca_pa,c(1,2),is.na))
```

## [1] 3034


```
sum(rowSums(apply(ca_pa,c(1,2),is.na))!=F)
```

## [1] 670


c 中统计为每一列中 na 的数量,累加后为 na 元素的数量。由于每一行可以包含多个 na,所以,最终统计至少包含一个 na 的行数为 670, 所以 (c),(e) 相符。

## 2 This Very New House

a.




b.




# 3 Nobody Home

a.



c.

4 COUNTYFP 6



可以看出,加州各个价位的房子都有空闲,而宾州的空房子主要集中在较低价位。此外,结合房屋建造的时间,说明可能宾州新建的房屋空闲概率较大。

## 4 COUNTYFP

a. 前一个循环用于找出 ca\_pa 中为于加州 Alameda County 的数据下标,后一个循环根据以上下标提取出相应 Median\_house\_value 这一列的数据, 最后求中位数。

b.

median((ca\_pa\_1 %>% filter(STATEFP == "06",COUNTYFP=="001"))\$Median\_house\_value)

## [1] 474050

5 MB.CH 1.11. 7

#### 5 MB.Ch 1.11.

```
gender <- factor(c(rep("female", 91), rep("male", 92)))</pre>
table(gender)
## gender
## female
             male
##
       91
               92
gender <- factor(gender, levels=c("male", "female"))</pre>
table(gender)
## gender
##
     male female
       92
               91
##
gender <- factor(gender, levels=c("Male", "female"))</pre>
# Note the mistake: "Male" should be "male"
table(gender)
## gender
##
     Male female
##
        0
               91
table(gender, exclude=NULL)
## gender
##
     Male female
                    <NA>
##
        0
               91
                      92
rm(gender)
```

首先建立一个 factor 类型的数据 gender, 其中前 91 个为 "female" 后 92 个为 "male"。之后重新设置 levels, 若能在 gender 内找到,就正常返回,

6 MB.CH 1.12.

若有设定外的 levels 则将其返回为 NA。默认下 table 不显示 NA 的值,有关 NA 的输出由参数 useNA 控制。最后一个操作中 exclude=NULL 参数表示不排除任何数据,但却将 useNA 默认为 "ifany",若 NA 个数为正,此时就会输出一个 levels。

### 6 MB.Ch 1.12.

```
exceed <- function(x,cutoff){
   sum(x>cutoff)/length(x)
}
exceed(1:100,60)

## [1] 0.4

exceed(1:100,0)

## [1] 1

exceed(1:100,19.5)
```

### 7 MB.Ch.1.18.

```
cbind(Treatment = unstack(Rabbit, Treatment ~ Animal)[,1],
     Dose = unstack(Rabbit, Dose ~ Animal)[,1],
     unstack(Rabbit, BPchange ~ Animal))
##
     Treatment
                               R2
                                     RЗ
                                               R5
                 Dose
                         R1
                                           R4
## 1
       Control
                 6.25 0.50 1.00 0.75 1.25 1.5
## 2
       Control 12.50 4.50 1.25 3.00 1.50 1.5
```

Control 25.00 10.00 4.00 3.00 6.00 5.0

Control 50.00 26.00 12.00 14.00 19.00 16.0

## 3

## 4

7 MB.CH.1.18. 9

```
Control 100.00 37.00 27.00 22.00 33.00 20.0
## 5
## 6
       Control 200.00 32.00 29.00 24.00 33.00 18.0
## 7
           MDL
                6.25 1.25 1.40 0.75 2.60 2.4
## 8
           MDL 12.50 0.75 1.70 2.30 1.20 2.5
## 9
           MDL 25.00 4.00 1.00 3.00 2.00 1.5
## 10
           MDL 50.00 9.00 2.00 5.00 3.00 2.0
## 11
           MDL 100.00 25.00 15.00 26.00 11.00 9.0
           MDL 200.00 37.00 28.00 25.00 22.00 19.0
## 12
```